

Anexo: respaldo para preguntas

Material de respaldo de la ponencia ID 129 (CICI 2026); se usa solo si hay preguntas

A1 Cuánto inflaba el resultado cada error

A2 y A3 Formulación detallada de los cinco algoritmos

A4 a A6 Selección de variables, hiperparámetros e importancia


A7 a A9 Comparaciones pareadas, curvas PR y ROC, elección del umbral

A10 a A13 Límites en detalle y robustez ante el plan 2018



Cuánto sobreestimaba el resultado cada error

El modelo parecía mejor de lo que era: el AUC-PR medido con el error supera al medido correctamente



Cinco algoritmos: 1 de 2

Rejilla de hiperparámetros

C: 0,01 a 100 (8 valores)
 peso de clase: no / balanceado
16 combinaciones

profundidad: 2, 3, 4, 5
 hoja mínima: 1, 2, 4
 criterio: Gini / entropía
24 combinaciones

profundidad: 2, 3, 4, sin límite
 hoja mínima: 1, 2, 4
 variables por corte: $\sqrt{p}$, todas
24 combinaciones

Regresión logística

suma ponderada -> probabilidad

Formulación

$$\hat{p}(\mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}}$$

$$\min_{\boldsymbol{\beta}} \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n \log(1 + e^{-y_i f(\mathbf{x}_i)})$$

Árbol de decisión

preguntas sucesivas que reducen la impureza

$$\text{Gini}(t) = 1 - \sum_k p_k^2 \quad H(t) = - \sum_k p_k \log_2 p_k$$

$$\Delta = I(t) - \frac{n_L}{n_t} I(t_L) - \frac{n_R}{n_t} I(t_R)$$

Random Forest

promedio de B = 150 árboles con bootstrap y variables al azar

$$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x})$$



Cinco algoritmos: 2 de 2

Formulación

Rejilla de hiperparámetros

XGBoost

árboles en secuencia: cada uno corrige al anterior

$$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta f_t(\mathbf{x})$$

$$\mathcal{L} = \sum_i \ell(y_i, \hat{y}_i) + \sum_k \left(\gamma T_k + \frac{1}{2} \lambda \|\mathbf{w}_k\|^2 \right)$$

árboles: 100, 200
 profundidad: 2, 3
 tasa η : 0,03, 0,1
 penalización λ : 0,5, 1, 2
24 combinaciones

SVM (kernel RBF)

frontera de máxima separación, curva

$$f(\mathbf{x}) = \sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b$$

$$K(\mathbf{x}_i, \mathbf{x}) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}\|^2)$$


C: 0,1 a 10 (5 valores)
 γ : scale, auto, 0,01, 0,1
20 combinaciones

Presupuesto equilibrado: 16-24 combinaciones por algoritmo, ante empate, el más simple: LR > Árbol > RF > XGBoost > SVM




¿Cuántas variables necesitamos?

Seis variables académicas rinden igual que las 19 candidatas




Hiperparámetros elegidos por Random Forest

Frecuencia en las 50 particiones externas: árboles poco profundos




Importancia por permutación

El promedio del 1.er semestre concentra la señal



Comparaciones pareadas

Diferencia de AUC-PR (fila – columna)
t corregida de Nadeau-Bengio




Prueba t corregida para validación cruzada repetida [12]

A7




Curvas de precisión-exhaustividad y ROC

Predicciones fuera de muestra, promediadas en las 10 repeticiones




Elección del umbral

Cuántos estudiantes acompañar lo decide la Universidad, no el modelo




Límite 1: casos simultáneos

42 % de los casos ocurre en el 1.er semestre: ahí el modelo confirma




Límite 2: calibración

Calibrar no mejora (se muestran niveles, no porcentajes)



Límite 3: predicción semestre a semestre

Sin señal sobre el azar: el seguimiento usa el reglamento



Robustez: cambio al plan 2018

El desempeño se mantiene; los umbrales se ajustarán con la primera cohorte



Referencias

- [1] Laboratorio de Economía de la Educación, «Deserción en la educación superior en Colombia», Informe No. 74, Pontificia Universidad Javeriana, 2023.
- [2] R. Wirth y J. Hipp, «CRISP-DM: Towards a standard process model for data mining», Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining, 2000, pp. 29-39.
- [3] IBM Corp., Guía de CRISP-DM de IBM SPSS Modeler (v. 18.3). Armonk, NY: IBM, 2021.
- [4] Universidad de los Llanos, Acuerdo Superior No. 020 de 2021: Reglamento Estudiantil de pregrado. Villavicencio, 2021.
- [5] S. Varma y R. Simon, «Bias in error estimation when using cross-validation for model selection», BMC Bioinformatics, vol. 7, p. 91, 2006.
- [6] G. C. Cawley y N. L. C. Talbot, «On over-fitting in model selection and subsequent selection bias in performance evaluation», J. Mach. Learn. Res., vol. 11, pp. 2079-2107, 2010.
- [7] C. Ambroise y G. J. McLachlan, «Selection bias in gene extraction on the basis of microarray gene-expression data», PNAS, vol. 99, no. 10, pp. 6562-6566, 2002.
- [8] T. Hastie, R. Tibshirani y J. Friedman, The Elements of Statistical Learning, 2.^a ed. Nueva York: Springer, 2009.
- [9] L. Breiman, «Random forests», Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [10] T. Chen y C. Guestrin, «XGBoost: A scalable tree boosting system», Proc. 22nd ACM SIGKDD, 2016, pp. 785-794.
- [11] C. Cortes y V. Vapnik, «Support-vector networks», Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
- [12] C. Nadeau e Y. Bengio, «Inference for the generalization error», Machine Learning, vol. 52, no. 3, pp. 239-281, 2003.
- [13] T. Saito y M. Rehmsmeier, «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets», PLoS ONE, vol. 10, no. 3, e0118432, 2015.
- [14] F. Pedregosa et al., «Scikit-learn: Machine learning in Python», J. Mach. Learn. Res., vol. 12, pp. 2825-2830, 2011.
- [15] Ministerio de Educación Nacional, SPADIES: Sistema para la Prevención de la Deserción de la Educación Superior. Bogotá: MEN.
- [16] C. Romero y S. Ventura, «Educational data mining: A review of the state of the art», IEEE Trans. Syst., Man, Cybern. C, vol. 40, no. 6, pp. 601-618, 2010.

