

Aprendizaje automático para predicción del éxito académico en Ingeniería de Sistemas

Joan D. Martínez-Hernández¹, Diana M. Cardona-Román², and Sara Cristina Guerrero³

Facultad de Ciencias Básicas e Ingeniería, Universidad de los Llanos, Villavicencio,
Colombia

{joan.martinez¹, dcardona², sguerrero³}@unillanos.edu.co

Abstract. En Colombia más de la mitad de quienes ingresan a la educación superior no logra graduarse tras quince semestres, y los programas de ingeniería de la Universidad de los Llanos reflejan la misma tendencia. El objetivo de este trabajo es comparar el desempeño de tres algoritmos de aprendizaje automático *Decision Tree*, *Random Forest* y *XGBoost* en la predicción del rendimiento académico y la graduación en Ingeniería de Sistemas. Bajo la metodología CRISP-DM se integraron seis fuentes institucionales de las cohortes 2017-2 y 2018-1 ($N = 90$); se depuraron y codificaron los registros, se utilizaron 18 variables de ingreso y primer semestre, y se evaluaron los algoritmos mediante validación cruzada estratificada de cinco pliegues. Random Forest alcanzó un mejor desempeño en la detección de bajo rendimiento, mientras que XGBoost lo hizo en la predicción de la graduación. Por otro lado, el promedio académico del estudiante del primer semestre concentró el 40,4 % de la importancia predictiva para explicar el éxito académico y su graduación.

Palabras clave: Analítica de datos educativos, Aprendizaje automático, CRISP-DM, Graduación, Rendimiento académico.

1 Introducción

En Colombia, más de la mitad de los estudiantes que ingresan a la educación superior no logra graduarse después de quince semestres: la tasa de graduación acumulada alcanza apenas el 45,1 % [1]. La Minería de Datos Educativos (EDM) anticipa el riesgo académico mediante modelos supervisados [2], y revisiones recientes confirman que *Decision Trees*, *Random Forest* y *Neural Networks* obtienen resultados altamente competitivos en este tipo de predicciones [3]. La predicción mediante algoritmos de aprendizaje automático depende en gran medida de la calidad de los datos [4]; en este sentido, el proceso demanda inicialmente la depuración y codificación de los registros entregados por las dependencias de la universidad.

El trabajo responde a un interrogante central: ¿cuál algoritmo ofrece el mejor desempeño predictivo del rendimiento académico? De manera complementaria se exploran algunos factores asociados: género, nivel educativo de los padres y repitencia escolar previa, y la identificación de las asignaturas más críticas.

2 Materiales y métodos

Se adoptó la metodología CRISP-DM [5], de carácter iterativo, que permitió retornar a fases previas ante las inconsistencias detectadas.

Comprensión de los datos. Se integraron seis fuentes institucionales: caracterización sociodemográfica, historial de asignaturas, estados administrativos, promedios y homologaciones. En conjunto aportaron 8503 registros de notas y 1968 registros de estado de las cohortes 2017-2 y 2018-1.

Preparación de los datos. Se contrastó la documentación del sistema con el contenido real de los registros, corrigiendo la *codificación* de observaciones mal documentadas y resolviendo la *completitud* de los estados faltantes desde la actividad registrada; cada regla se documentó para garantizar trazabilidad. Así se recuperaron 76 registros, se imputaron 541 estados y se descartaron 17 posteriores a la graduación, sin alterar las fuentes originales.

Población y variables. Se partió de la totalidad de admitidos en ambas cohortes ($N = 95$) y se excluyeron cinco estudiantes sin actividad académica ($N = 90$). El conjunto se dividió en entrenamiento (72) y prueba (18) mediante partición estratificada por la variable objetivo, que preservó su proporción en ambos subconjuntos (41,7% y 44,4% de bajo rendimiento); de modo que el subconjunto de validación es representativo del total. Se incluyeron 18 variables: sociodemográficas, familiares, de SABER 11 y de primer semestre, seleccionadas por disponibilidad temporal: solo lo observable al ingreso o al cierre del primer periodo, evitando fuga de información. Las variables objetivo fueron bajo rendimiento (promedio $< 3,0$; 42,2 %) y graduación (38,9 %).

Modelado y evaluación. Se evaluaron *Decision Tree* [6], *Random Forest* y *XGBoost*. Los hiperparámetros se ajustaron por búsqueda en malla con validación cruzada estratificada de cinco pliegues y semilla fija; profundidades máximas de 2 a 5, 200 árboles en *Random Forest* y tasas de aprendizaje de 0,05 a 0,10 en *XGBoost*. El desempeño se estimó con predicciones *out-of-fold*, sin sobremuestreo dado el balance natural de las clases, reportando exhaustividad, precisión, F1-macro, AUC-ROC, exactitud y coeficientes de Mann-Whitney y de Spearman. Para bajo rendimiento el umbral se fijó en 0,29, priorizando la exhaustividad porque el falso negativo es el error más costoso en alertas tempranas [8]. Adicionalmente, las 52 asignaturas con al menos 20 estudiantes se ordenaron por un índice descriptivo de criticidad que pondera la tasa de reprobación (0,70) y la repitencia media (0,30), ambas escaladas al intervalo $[0, 1]$.

3 Resultados

En la población estudiada, el 63 % de los estudiantes no registró graduación dentro de la ventana observada; entre quienes interrumpieron su actividad académica, el 64 % lo hizo tras dos periodos o menos. La Tabla 1 resume el desempeño de los algoritmos. Para bajo rendimiento, *Random Forest* con umbral 0,29 obtuvo la mayor exhaustividad (0,816), detectando 8 de cada 10 estudiantes en riesgo; para graduación, *XGBoost* alcanzó el mayor AUC (0,853). El promedio del primer

semestre dominó en ambos modelos, con 40,4 % y 19,7 % de la importancia (Fig. 1).




Fig. 1. Importancia de las cinco variables principales en cada modelo ganador.

Tabla 1. Comparativa de modelos en validación cruzada de cinco pliegues ($N = 90$).

Objetivo	Modelo	Exhaust.	Precisión	F1-mac	AUC	MCC	Exactitud
Bajo rendimiento ($u=0,29$)	Decision Tree	0,632	0,667	0,702	0,702	0,404	0,711
	Random Forest ✓	0,816	0,484	0,548	0,752	0,197	0,556
	XGBoost	0,737	0,596	0,677	0,776	0,367	0,678
Graduación ($u=0,50$)	Decision Tree	0,686	0,686	0,743	0,728	0,486	0,756
	Random Forest	0,657	0,821	0,792	0,844	0,596	0,811
	XGBoost ✓	0,600	0,808	0,764	0,853	0,548	0,789

Entre los factores explorados no se evidenciaron diferencias significativas por género (U de Mann-Whitney, $p = 0,246$) [7], correlación con el nivel educativo de los padres (Spearman, $p > 0,6$) ni asociación con la repitencia escolar previa (χ^2 , $p = 0,215$). Estos resultados negativos, condicionados por el tamaño de los subgrupos, son consistentes con la dominancia del desempeño académico temprano (Fig. 1).

Las cinco asignaturas de mayor índice de criticidad fueron Matemáticas II, Física I, Álgebra Lineal, Matemáticas I y Fundamentos de Programación (Fig. 2), todas ellas de los primeros semestres del plan de estudios.



Fig. 2. Aplicación en Streamlit: índice de criticidad de las cinco asignaturas con mayor valor.

4 Conclusiones

De los tres algoritmos evaluados, *Random Forest* resultó el más adecuado para predecir el bajo rendimiento (exhaustividad 0,816 con umbral 0,29), mientras que *XGBoost* obtuvo el mayor AUC en graduación (0,853); ninguno dominó ambos objetivos. En los dos modelos el promedio del primer semestre fue la variable dominante, lo que permite activar alertas tempranas al cierre del primer periodo; las variables sociodemográficas y familiares no mostraron diferencias ni asociaciones significativas en esta población. Las cinco asignaturas de mayor criticidad se concentran en los primeros semestres, lo que habilita intervenciones focalizadas en el mismo periodo en que el modelo emite su primera alerta.

Como trabajo futuro se extenderá el análisis a los otros programas de la Facultad de Ciencias Básicas e Ingeniería con una variable objetivo multiclase de trayectoria y diseño longitudinal por corte semestral.

Agradecimientos. Los autores agradecen al proyecto DGI/Unillanos C07-02-2026-027.

Referencias

1. Laboratorio de Economía de la Educación, “Deserción en la educación superior en Colombia,” Informe de análisis estadístico No. 74, Pontificia Universidad Javeriana, Bogotá, Colombia, 2023.
2. C. Romero and S. Ventura, “Educational data mining: A review of the state of the art,” *IEEE Trans. Syst., Man, Cybern. C*, vol. 40, no. 6, pp. 601–618, 2010.
3. A. M. Shahiri, W. Husain, and N. A. Rashid, “A review on predicting student's performance using data mining techniques,” *Procedia Comput. Sci.*, vol. 72, pp. 414–422, 2015.
4. L. L. Pipino, Y. W. Lee, and R. Y. Wang, “Data quality assessment,” *Commun. ACM*, vol. 45, no. 4, pp. 211–218, 2002.
5. R. Wirth and J. Hipp, “CRISP-DM: Towards a standard process model for data mining,” in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining*, 2000, pp. 29–39.
6. L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone, *Classification and Regression Trees*. Belmont, CA, USA: Wadsworth, 1984.
7. S. C. Guerrero and R. L. Espejo, “Deserción universitaria: estudio comparativo entre Colombia y España desde la perspectiva de género,” *Formación Universitaria*, vol. 17, no. 2, pp. 101–112, 2024.
8. T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, 2006.