


Aprendizaje automático para predicción del éxito académico en Ingeniería de Sistemas

Joan David Martínez Hernández* - Diana Marcela Cardona Román - Sara Cristina Guerrero

Facultad de Ciencias Básicas e Ingeniería - Universidad de los Llanos - Villavicencio, Meta, Colombia

Proyecto DGI/Unillanos C07-02-2026-027



El problema del abandono

Más de la mitad no se gradúa y, en Ingeniería de Sistemas (Unillanos), el abandono es temprano

45,1 %

Graduación nacional

tras 15 semestres (LEE, 2023) [1]

63 %

Sin graduación

cohortes 2017-2 y 2018-1
Ingeniería de Sistemas

64 %

Abandono temprano

de quienes abandonan, lo hacen
en los dos primeros semestres

PREGUNTA


¿Cuál algoritmo ofrece el mejor desempeño predictivo del rendimiento académico?

OBJETIVO

Comparar el desempeño de algoritmos de aprendizaje automático en la predicción del rendimiento académico y la graduación en Ingeniería de Sistemas


¿Cuándo abandonan?

La alerta debe llegar al cierre del 1.er semestre



Metodología CRISP-DM


Seis fases, con regresos (rojo) cuando la evidencia lo exigió



Derecha: proceso CRISP-DM adaptado al proyecto de trayectoria académica FCBI, basado en el ciclo de vida de minería de datos de IBM [3] y en el modelo de referencia CRISP-DM [2].

Los datos

Seis fuentes administrativas del SIIF, limpiadas con reglas escritas



8503 notas /calificaciones

1968 estados por semestre

541 estados completados

76 registros recuperados

Resultados preliminares

Validación cruzada de 5 particiones

N = 90 , tres algoritmos

Objetivo	Modelo	Exhaust.	Precisión	AUC
Bajo rendimiento	Árbol de decisión	0,632	0,667	0,702
	Random Forest	0,816	0,484	0,752
	XGBoost	0,737	0,596	0,776
Graduación	Árbol de decisión	0,686	0,686	0,728
	Random Forest	0,657	0,821	0,844
	XGBoost	0,600	0,808	0,853

40,4 %


de la importancia del modelo
corresponde al promedio del
1er semestre

Exhaustividad: casos en riesgo detectados. AUC: 1 = perfecto · 0,5 = azar.


Factores sin relación con el rendimiento

Resultados negativos: tampoco son predictores útiles en esta población


Género · Mann-Whitney $p = 0,246$



Educación de los padres · Spearman $p > 0,6$




Repetencia escolar · χ^2 $p = 0,215$




Asignaturas críticas

El orden se conserva al traducir al plan 2018: el apoyo va al primer año



Equivalencias entre planes de estudio

72 equivalencias oficiales (Res. 036 de 2017), en rojo las críticas



Antes de desplegar, se audita

Tres problemas de diseño experimental

1 • Variable objetivo

El promedio de carrera contenía al predictor

Ahora

**Art. 19 del Reglamento:
Definición de Bajo
rendimiento** [4]

2 • Hiperparámetros

Se ajustaban viendo los datos de evaluación

Ahora

Validación anidada [5], [6]

3 • Selección de variables

Se elegían con toda la muestra


Ahora

Dentro de cada partición
[7], [8]

[4] Reglamento Estudiantil, Acuerdo Superior 020 de 2021 · [5] Varma y Simon, 2006 · [6] Cawley y Talbot, 2010 · [7] Ambroise y McLachlan, 2002 · [8] Hastie, Tibshirani y Friedman, 2009, §7.10.2

Cuánto sobreestimaba el resultado cada error

El modelo parecía mejor de lo que era: el AUC-PR medido con el error supera al medido correctamente



Variable objetivo y variables

Todo lo que el modelo usa existe al cierre del 1er semestre

Variable objetivo

Art. 19 del Reglamento Estudiantil

pérdida de la calidad de estudiante por bajo rendimiento

19 casos de 80

prevalencia 0,2375 = AUC-PR del azar

Seis variables (conjunto S3:ganador)

Promedio del 1.er semestre	académica
Sin primer semestre	indicador
Saber 11 · total	ingreso
Saber 11 · matemáticas	ingreso
Saber 11 · lectura crítica	ingreso
Saber 11 · c. naturales	ingreso

Cinco algoritmos: 1 de 2

Formulación

Rejilla de hiperparámetros

Regresión logística

suma ponderada -> probabilidad

$$\hat{p}(\mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}}$$

$$\min_{\boldsymbol{\beta}} \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n \log(1 + e^{-y_i f(\mathbf{x}_i)})$$

C: 0,01 a 100 (8 valores)
peso de clase: no / balanceado
16 combinaciones

Árbol de decisión

preguntas sucesivas que reducen la impureza

$$\text{Gini}(t) = 1 - \sum_k p_k^2 \quad H(t) = - \sum_k p_k \log_2 p_k$$

$$\Delta = I(t) - \frac{n_L}{n_t} I(t_L) - \frac{n_R}{n_t} I(t_R)$$

profundidad: 2, 3, 4, 5
hoja mínima: 1, 2, 4
criterio: Gini / entropía
24 combinaciones

Random Forest

promedio de B = 150 árboles con bootstrap y variables al azar

$$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x})$$

profundidad: 2, 3, 4, sin límite
hoja mínima: 1, 2, 4
variables por corte: $\sqrt{p}$, todas
24 combinaciones



Cinco algoritmos: 2 de 2

Formulación

Rejilla de hiperparámetros

XGBoost

árboles en secuencia: cada uno corrige al anterior

$$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta f_t(\mathbf{x})$$

$$\mathcal{L} = \sum_i \ell(y_i, \hat{y}_i) + \sum_k \left(\gamma T_k + \frac{1}{2} \lambda \|\mathbf{w}_k\|^2 \right)$$

árboles: 100, 200
 profundidad: 2, 3
 tasa η : 0,03, 0,1
 penalización λ : 0,5, 1, 2
24 combinaciones

SVM (kernel RBF)

frontera de máxima separación, curva

$$f(\mathbf{x}) = \sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b$$

$$K(\mathbf{x}_i, \mathbf{x}) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}\|^2)$$


C: 0,1 a 10 (5 valores)
 γ : scale, auto, 0,01, 0,1
20 combinaciones

Presupuesto equilibrado: 16-24 combinaciones por algoritmo, ante empate, el más simple: LR > Árbol > RF > XGBoost > SVM




Validación cruzada anidada

Los datos de evaluación nunca participan en una decisión del modelo




¿Cuántas variables necesitamos?

Seis variables académicas rinden igual que las 19 candidatas




Hiperparámetros elegidos por Random Forest

Frecuencia en las 50 particiones externas: árboles poco profundos



Importancia por permutación


El promedio del 1.er semestre concentra la señal



Comparación de algoritmos: métrica AUC-PR

80 estudiantes - 10 repeticiones $\times$ 5 particiones


$$AP = \sum_n (R_n - R_{n-1}) P_n$$



AUC-PR como métrica para clases desbalanceadas [13]

Comparaciones pareadas


Diferencia de AUC-PR (fila – columna)
t corregida de Nadeau-Bengio



Prueba t corregida para validación cruzada repetida [12]


Curvas de precisión-exhaustividad y ROC

Predicciones fuera de muestra, promediadas en las 10 repeticiones




Matrices de confusión: dos niveles de alerta

Porcentaje sobre cada fila; entre paréntesis, número de estudiantes




Elección del umbral

Cuántos estudiantes acompañar lo decide la Universidad, no el modelo




Segundo objetivo: graduación

SVM y Random Forest empatan ($p = 0,39$), se elige Random Forest




Límite 1: casos simultáneos

42 % de los casos ocurre en el 1.er semestre: ahí el modelo confirma




Límite 2: calibración

Calibrar no mejora (se muestran niveles, no porcentajes)



Límite 3: predicción semestre a semestre

Sin señal sobre el azar: el seguimiento usa el reglamento




Robustez: cambio al plan 2018

El desempeño se mantiene; los umbrales se ajustarán con la primera cohorte



TRAYECTA

Alerta y trayectoria académica
referencia: SPADIES, a escala de programa



	SPADIES (nacional)	TRAYECTA (este trabajo)
Unidad	instituciones del país	un programa
Criterio de riesgo	deserción	Reglamento: arts. 19, 20 y 21
Planes de estudio	fuera de su alcance	equivalencias 2011 ↔ 2018

Referencia de producto: SPADIES, Ministerio de Educación Nacional [15]

Demostración: panorama de la cohorte

Cohorte simulada · modelos entrenados con los datos reales



Demostración: ficha y carga de cohortes

Recorrido semestre a semestre · validación del plan de estudios



Cargar una cohorte plan 2011 (602xxx), plan 2018 (603xxx) o mezclados

Materias cursadas Ingreso (Saber 11)

Upload 200MB per file • CSV, XLSX Upload 200MB per file • CSV, XLSX

Plantilla de materias Plantilla de ingreso

☒ Probar con la cohorte A (sintética)

VALIDACIÓN DE LA COHORTE

✓ **Lista para procesar** 48 1620 0 5

plan IS-2011 plan IS-2018

estudiantes registros de notas códigos fuera del catálogo con planes mezclados

Cómo se tradujo cada registro

Art. 2 · 1016 institucional · 241 sin equivalente · 158 Art. 1 · 127 propio · 78

Al cargar una cohorte
reconoce el plan, valida cada código y
advierte planes mezclados

| Conclusiones

1

Random Forest es el más adecuado

AUC-PR 0,745: tres veces el azar

2

El 1.er semestre concentra la señal

alerta a tiempo, cuando ocurre el abandono

3

Medir bien pesa más que el algoritmo

los sesgos inflaban hasta 15 puntos

4

La calidad en los datos es determinante para establecer una metodología viable

Antes de pensar en el modelo, los datos deben ser confiables, consistentes y relevantes. **Un buen modelo comienza con buenos datos.**

Referencias

- [1] Laboratorio de Economía de la Educación, «Deserción en la educación superior en Colombia», Informe No. 74, Pontificia Universidad Javeriana, 2023.
- [2] R. Wirth y J. Hipp, «CRISP-DM: Towards a standard process model for data mining», Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining, 2000, pp. 29-39.
- [3] IBM Corp., Guía de CRISP-DM de IBM SPSS Modeler (v. 18.3). Armonk, NY: IBM, 2021.
- [4] Universidad de los Llanos, Acuerdo Superior No. 020 de 2021: Reglamento Estudiantil de pregrado. Villavicencio, 2021.
- [5] S. Varma y R. Simon, «Bias in error estimation when using cross-validation for model selection», BMC Bioinformatics, vol. 7, p. 91, 2006.
- [6] G. C. Cawley y N. L. C. Talbot, «On over-fitting in model selection and subsequent selection bias in performance evaluation», J. Mach. Learn. Res., vol. 11, pp. 2079-2107, 2010.
- [7] C. Ambroise y G. J. McLachlan, «Selection bias in gene extraction on the basis of microarray gene-expression data», PNAS, vol. 99, no. 10, pp. 6562-6566, 2002.
- [8] T. Hastie, R. Tibshirani y J. Friedman, The Elements of Statistical Learning, 2.^a ed. Nueva York: Springer, 2009.
- [9] L. Breiman, «Random forests», Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [10] T. Chen y C. Guestrin, «XGBoost: A scalable tree boosting system», Proc. 22nd ACM SIGKDD, 2016, pp. 785-794.
- [11] C. Cortes y V. Vapnik, «Support-vector networks», Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
- [12] C. Nadeau e Y. Bengio, «Inference for the generalization error», Machine Learning, vol. 52, no. 3, pp. 239-281, 2003.
- [13] T. Saito y M. Rehmsmeier, «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets», PLoS ONE, vol. 10, no. 3, e0118432, 2015.
- [14] F. Pedregosa et al., «Scikit-learn: Machine learning in Python», J. Mach. Learn. Res., vol. 12, pp. 2825-2830, 2011.
- [15] Ministerio de Educación Nacional, SPADIES: Sistema para la Prevención de la Deserción de la Educación Superior. Bogotá: MEN.
- [16] C. Romero y S. Ventura, «Educational data mining: A review of the state of the art», IEEE Trans. Syst., Man, Cybern. C, vol. 40, no. 6, pp. 601-618, 2010.




Límites y siguiente paso

- ▶ Una sola muestra de 80 estudiantes: estudio exploratorio
- ▶ Validación con cohortes recientes, sin modificar el modelo
- ▶ Extensión a Ingeniería Electrónica y Biología

¡Gracias!

joan.martinez@unillanos.edu.co



Curva de aprendizaje: aún sube (techo ≈ 0,84)

Proyecto DGI/Unillanos C07-02-2026-027 · Oficina de Sistemas, Universidad de los Llanos