

Aprendizaje automático para predicción del éxito académico en Ingeniería de Sistemas

Joan David Martínez Hernández
Diana Marcela Cardona Román
Sara Cristina Guerrero

Facultad de Ciencias Básicas e Ingeniería - Universidad de los Llanos - Villavicencio, Meta, Colombia

Proyecto DGI/Unillanos C07-02-2026-027



El problema del abandono

Más de la mitad no se gradúa y, en Ingeniería de Sistemas (Unillanos), el abandono es temprano

45,1 %

Graduación nacional

tras 15 semestres (LEE, 2023) [1]

63 %

Sin graduación

cohortes 2017-2 y 2018-1
Ingeniería de Sistemas

64 %

Abandono temprano

de quienes abandonan, lo hacen
en los dos primeros semestres

PREGUNTA


¿Cuál algoritmo ofrece el mejor desempeño predictivo del rendimiento académico?

OBJETIVO

Comparar el desempeño de algoritmos de aprendizaje automático en la predicción del rendimiento académico y la graduación en Ingeniería de Sistemas

¿Cuándo abandonan?



La alerta debe llegar al cierre del 1.er semestre



Metodología CRISP-DM

Cross-Industry Standard Process for Data Mining


Seis fases:



proceso CRISP-DM adaptado al proyecto de trayectoria académica FCBI, basado en el ciclo de vida de minería de datos de IBM [3] y en el modelo de referencia CRISP-DM [2].

Los datos

Seis fuentes administrativas del SIIF, limpiadas con reglas escritas



8503 notas /calificaciones

1968 estados

541 estados completados

76 registros recuperados

Las cohortes se estudiaron con el Acuerdo 015 de 2003 y, desde 2022-1, con el Acuerdo 020 de 2021. Se aplica el vigente a toda la trayectoria (supuesto declarado).

Punto de partida: resultados preliminares

N = 90 estudiantes, 18 variables, tres algoritmos, validación cruzada de 5 particiones

Objetivo	Modelo	Exhaustividad	Precisión	AUC
Bajo rendimiento	Árbol de decisión	0,632	0,667	0,702
	Random Forest	0,816	0,484	0,752
	XGBoost	0,737	0,596	0,776
Graduación	Árbol de decisión	0,686	0,686	0,728
	Random Forest	0,657	0,821	0,844
	XGBoost	0,600	0,808	0,853

Verde: modelo destacado en el informe preliminar (bajo rendimiento por exhaustividad; graduación por AUC). **Negrita:** mejor valor de cada métrica por objetivo.

Exhaustividad: casos reales detectados. Precisión: alertas correctas. AUC: 1 = separación perfecta; 0,5 = azar.

18 variables, cinco bloques

Sociodemográficas y escolares **7**

Familiares **5**

Saber 11 **4**

Primer semestre **1**




Cohorte **1**

40,4 %

de la importancia del modelo
corresponde al promedio del 1.er
semestre


Factores sin asociación significativa

Mann-Whitney, Spearman y χ^2 (N = 90): con grupos pequeños, no detectar asociación no prueba que no exista




Asignaturas críticas

El orden se conserva al traducir al plan 2018: el apoyo va al primer año



Equivalencias entre planes de estudio

72 equivalencias oficiales (Res. 036 de 2017), en rojo las críticas




 asignatura crítica (top 5 del índice de criticidad)

los intentos de un mismo curso se suman entre planes

Antes de desplegar, se audita

Tres problemas de diseño que inflaban el resultado medido



[4] Reglamento Estudiantil, Acuerdo Superior 020 de 2021; [5] Varma y Simon, 2006; [6] Cawley y Talbot, 2010; [7] Ambroise y McLachlan, 2002; [8] Hastie, Tibshirani y Friedman, 2009, 7.10.2

Variable objetivo y variables

Todo lo que el modelo usa existe al cierre del 1er semestre

Variable objetivo

Art. 19 del Reglamento Estudiantil

pérdida de la calidad de estudiante por bajo rendimiento

19 casos de 80

línea base 0,24: lo que obtendría un modelo que asigna el riesgo al azar; el modelo debe superarla

Seis variables (conjunto S3:ganador)

Promedio del 1.er semestre	académica
Sin primer semestre	indicador
Saber 11: total	ingreso
Saber 11: matemáticas	ingreso
Saber 11: lectura crítica	ingreso
Saber 11: c. naturales	ingreso

Cinco algoritmos

Presupuesto equilibrado: 16 a 24 combinaciones de hiperparámetros por algoritmo


Algoritmo	Formulación	Hiperparámetros	Comb.
Regresión logística	$\hat{p}(\mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})$	C: 0,01 a 100 (8 valores) peso de clase: no / balanceado	16
Árbol de decisión	$\text{Gini}(t) = 1 - \sum_k p_k^2$	profundidad: 2 a 5; hoja mínima: 1, 2, 4 criterio: Gini / entropía	24
Random Forest	$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x})$	B = 150; profundidad: 2, 3, 4, sin límite hoja mínima: 1, 2, 4; variables: $\sqrt{p}$ / todas	24
XGBoost	$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta f_t(\mathbf{x})$	árboles: 100, 200; profundidad: 2, 3 η : 0,03, 0,1; λ : 0,5, 1, 2	24
SVM (kernel RBF)	$f(\mathbf{x}) = \sum_i \alpha_i y_i e^{-\gamma \ \mathbf{x}_i - \mathbf{x}\ ^2} + b$	C: 0,1 a 10 (5 valores) γ : scale, auto, 0,01, 0,1	20

Regresión logística y árbol de decisión [8]; Random Forest [9]; XGBoost [10]; SVM [11]; implementación en scikit-learn [14]



Validación cruzada anidada

Los datos de evaluación nunca participan en una decisión del modelo




Validación cruzada anidada [5], [6]; prueba t corregida [12]

Comparación de algoritmos: métrica AUC-PR

80 estudiantes - 10 repeticiones $\times$ 5 particiones


$$AP = \sum_n (R_n - R_{n-1}) P_n$$



AUC-PR como métrica para clases desbalanceadas [13]


Matrices de confusión: dos niveles de alerta

Porcentaje sobre cada fila; entre paréntesis, número de estudiantes



Segundo objetivo: graduación

SVM y Random Forest empatan ($p = 0,39$), se elige Random Forest



Límites declarados

Definen cómo se usa el modelo

1 Casos simultáneos

HALLAZGO

42 % de los casos ocurre en el 1.er semestre: ahí el modelo confirma, no anticipa

$3,1 \times$ azar

Solo casos futuros (n = 72): 0,47 vs. 0,15

DECISIÓN

La alerta temprana sigue siendo útil para los casos posteriores

2 Calibración

HALLAZGO

Calibrar las probabilidades (isotónica y Platt) no mejora al modelo original

Sin mejora

en la curva de calibración

DECISIÓN

Se muestran niveles de alerta, no porcentajes

3 Semestre a semestre

HALLAZGO

Predecir en cortes sucesivos de la carrera no supera al azar

lift $\approx$ 1


Random Forest por corte: 1,09; 0,93; 1,27

DECISIÓN

El seguimiento semestral aplica las reglas del reglamento

TRAYECTA

Alerta y trayectoria académica
referencia: SPADIES, a escala de programa



	SPADIES (nacional)	TRAYECTA (este trabajo)
Unidad	instituciones del país	un programa
Criterio de riesgo	deserción	Reglamento: arts. 19, 20 y 21
Planes de estudio	fuera de su alcance	equivalencias 2011 ↔ 2018

Pruébela

cohortes simuladas
proyecto-trayectoria-
academica.streamlit.app

Referencia de producto: SPADIES, Ministerio de Educación Nacional [15]




TRAYECTA en uso

Cohorte simulada, modelos entrenados con los datos reales



Panorama: riesgo de cada estudiante y situación frente al reglamento



Ficha: recorrido semestre a semestre y condiciones activadas

En línea: <https://proyecto-trayectoria-academica.streamlit.app>

| Conclusiones

1

Random Forest es el más adecuado

AUC-PR 0,745: tres veces el azar

2

El 1.er semestre concentra la señal

alerta a tiempo, cuando ocurre el abandono

3

Medir bien pesa más que el algoritmo

los sesgos inflaban hasta 15 puntos

4

La calidad en los datos es determinante para establecer una metodología viable

Antes de pensar en el modelo, los datos deben ser confiables, consistentes y relevantes. **Un buen modelo comienza con buenos datos.**

Límites y siguiente paso


- ▶ Una sola muestra de 80 estudiantes: estudio exploratorio
- ▶ Validación con cohortes recientes, sin modificar el modelo
- ▶ Extensión a Ingeniería Electrónica y Biología

¡Gracias!

joan.martinez@unillanos.edu.co



proyecto-trayectoria-academica.streamlit.app



Curva de aprendizaje: aún sube (techo $\approx 0,84$)

Proyecto DGI/Unillanos C07-02-2026-027, Oficina de Sistemas, Universidad de los Llanos

Referencias

- [1] Laboratorio de Economía de la Educación, «Deserción en la educación superior en Colombia», Informe No. 74, Pontificia Universidad Javeriana, 2023.
- [2] R. Wirth y J. Hipp, «CRISP-DM: Towards a standard process model for data mining», Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining, 2000, pp. 29-39.
- [3] IBM Corp., Guía de CRISP-DM de IBM SPSS Modeler (v. 18.3). Armonk, NY: IBM, 2021.
- [4] Universidad de los Llanos, Acuerdo Superior No. 020 de 2021: Reglamento Estudiantil de pregrado. Villavicencio, 2021.
- [5] S. Varma y R. Simon, «Bias in error estimation when using cross-validation for model selection», BMC Bioinformatics, vol. 7, p. 91, 2006.
- [6] G. C. Cawley y N. L. C. Talbot, «On over-fitting in model selection and subsequent selection bias in performance evaluation», J. Mach. Learn. Res., vol. 11, pp. 2079-2107, 2010.
- [7] C. Ambroise y G. J. McLachlan, «Selection bias in gene extraction on the basis of microarray gene-expression data», PNAS, vol. 99, no. 10, pp. 6562-6566, 2002.
- [8] T. Hastie, R. Tibshirani y J. Friedman, The Elements of Statistical Learning, 2.^a ed. Nueva York: Springer, 2009.
- [9] L. Breiman, «Random forests», Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [10] T. Chen y C. Guestrin, «XGBoost: A scalable tree boosting system», Proc. 22nd ACM SIGKDD, 2016, pp. 785-794.
- [11] C. Cortes y V. Vapnik, «Support-vector networks», Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
- [12] C. Nadeau e Y. Bengio, «Inference for the generalization error», Machine Learning, vol. 52, no. 3, pp. 239-281, 2003.
- [13] T. Saito y M. Rehmsmeier, «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets», PLoS ONE, vol. 10, no. 3, e0118432, 2015.
- [14] F. Pedregosa et al., «Scikit-learn: Machine learning in Python», J. Mach. Learn. Res., vol. 12, pp. 2825-2830, 2011.
- [15] Ministerio de Educación Nacional, SPADIES: Sistema para la Prevención de la Deserción de la Educación Superior. Bogotá: MEN.
- [16] C. Romero y S. Ventura, «Educational data mining: A review of the state of the art», IEEE Trans. Syst., Man, Cybern. C, vol. 40, no. 6, pp. 601-618, 2010.

