

Teleprompter · ID 129 · CICI 2026 (15 min)

Lea a un ritmo de unas 125 palabras por minuto. Cada bloque corresponde a una lámina y explica lo que esta muestra: puede leerse junto a la presentación sin conocer el proyecto. Lo que va entre corchetes es una indicación escénica y no se lee. Si la demo en vivo falla, use las capturas de las láminas 30 y 31 como respaldo. La última sección no corresponde a ninguna lámina: es apoyo para las preguntas.

Lámina	Tema	Inicio	Duración	Palabras
1	Portada	0:00	0:15	34
2	El problema del abandono	0:15	0:45	100
3	¿Cuándo abandonan?	1:00	0:25	51
4	Metodología CRISP-DM	1:25	0:30	66
5	Los datos	1:55	0:35	71
6	Resultados preliminares	2:30	0:30	68
7	Factores sin relación	3:00	0:20	45
8	Asignaturas críticas	3:20	0:35	72
9	Equivalencias entre planes	3:55	0:25	57
10	Antes de desplegar, auditamos	4:20	0:40	89
11	Cuánto sobreestimaba el resultado cada error	5:00	0:35	71
12	Fase 4 · Objetivo y variables	5:35	0:25	57
13	Fase 4 · Algoritmos (1 de 2)	6:00	0:35	76
14	Fase 4 · Algoritmos (2 de 2)	6:35	0:30	65
15	Fase 4 · Validación cruzada anidada	7:05	0:30	63
16	Fase 4 · ¿Cuántas variables?	7:35	0:15	36
17	Fase 4 · Hiperparámetros elegidos	7:50	0:20	40
18	Fase 4 · Importancia de las variables	8:10	0:10	24
19	Fase 5 · Comparación de algoritmos	8:20	0:30	66
20	Fase 5 · Comparaciones pareadas	8:50	0:25	50

21	Fase 5 · Curvas PR y ROC	9:15	0:15	31
22	Fase 5 · Matrices de confusión	9:30	0:50	104
23	Fase 5 · Elección del umbral	10:20	0:15	32
24	Fase 5 · Graduación	10:35	0:20	41
25	Límite 1 · Casos simultáneos	10:55	0:20	45
26	Límite 2 · Calibración	11:15	0:10	23
27	Límite 3 · Semestre a semestre	11:25	0:20	41
28	Robustez · Plan 2018	11:45	0:15	36
29	Fase 6 · TRAYECTA	12:00	0:30	66
30	Demostración · Panorama	12:30	0:30	59
31	Demostración · Ficha y carga	13:00	0:30	61
32	Conclusiones	13:30	0:35	77
33	Referencias	14:05	0:05	19
34	Límites y siguiente paso	14:10	0:35	71
A	Apoyo para preguntas (sin lámina)	anexo	—	208

Lámina 1 · Portada · 0:00 (0:15)

Buenos días. Mi nombre es Joan David Martínez, estudiante de Ingeniería de Sistemas de la Universidad de los Llanos. Presento el trabajo 129, desarrollado con las profesoras Diana Marcela Cardona y Sara Cristina Guerrero.

Lámina 2 · El problema del abandono · 0:15 (0:45)

Empecemos por el tamaño del problema. En Colombia, solo el 45 por ciento de quienes ingresan a la educación superior se gradúa después de quince semestres. En las dos cohortes de Ingeniería de Sistemas que estudiamos, las que ingresaron en 2017 y 2018, el 63 por ciento no se había graduado, y de quienes abandonaron, casi dos de cada tres lo hicieron en los dos primeros semestres. De ahí nuestra pregunta: ¿cuál algoritmo ofrece el mejor desempeño predictivo del rendimiento académico? El objetivo es comparar algoritmos de aprendizaje automático para predecir el rendimiento y la graduación en Ingeniería de Sistemas.

Lámina 3 · ¿Cuándo abandonan? · 1:00 (0:25)

Esta gráfica lo muestra en detalle. Cada barra cuenta a los estudiantes según cuántos semestres alcanzaron a cursar antes de abandonar. Las barras rojas, de cero a dos semestres, reúnen 38 de los 59 casos. Por eso, si queremos ayudar a tiempo, la alerta debe llegar al terminar el primer semestre.

Lámina 4 · Metodología CRISP-DM · 1:25 (0:30)

Seguimos CRISP-DM, la metodología más usada en minería de datos, que organiza el proyecto en seis fases. A la derecha está la versión que adaptamos al proyecto, basada en la guía de IBM. A la izquierda, las flechas rojas muestran que el camino no fue lineal: la evaluación nos obligó a volver a preparar los datos, y el modelado nos llevó a redefinir la variable objetivo.

Lámina 5 · Los datos · 1:55 (0:35)

Trabajamos con seis archivos de la Oficina de Sistemas: más de ocho mil quinientas notas y casi dos mil registros del estado de cada estudiante en cada semestre. La mayor parte del trabajo fue limpiarlos con reglas escritas, sin tocar los originales. El embudo muestra el resultado: de 95 admitidos, 90 tuvieron actividad académica, 80 alcanzaron a estar sujetos al reglamento y 19 perdieron la calidad de estudiante por bajo rendimiento.

Lámina 6 · Resultados preliminares · 2:30 (0:30)

Esta tabla resume nuestros resultados preliminares, obtenidos con validación cruzada de cinco particiones. La exhaustividad es la proporción de estudiantes en riesgo que el modelo detecta; el AUC mide qué tan bien separa los dos grupos: 1 es perfecto y 0,5 es azar. Random Forest detectó ocho de cada diez casos de bajo rendimiento, y el promedio del primer semestre concentró el 40 por ciento de la importancia.

Lámina 7 · Factores sin relación · 3:00 (0:20)

También hay resultados negativos que vale la pena reportar. El género, la educación de los padres y haber repetido un año escolar no mostraron relación significativa con el rendimiento. Con grupos tan pequeños esto no prueba que no influyan, pero aquí no sirven para predecir.

Lámina 8 · Asignaturas críticas · 3:20 (0:35)

¿Dónde se pierde el semestre? Calculamos un índice de criticidad que pondera en 70 por ciento la tasa de reprobación y en 30 por ciento las repeticiones. Los puntos rojos corresponden al plan 2011 y los azules a su equivalente en el plan 2018. Matemáticas II, Física I y Álgebra Lineal encabezan la lista, y el orden se conserva al traducir: el apoyo debe ir a los mismos cursos del primer año.

Lámina 9 · Equivalencias entre planes · 3:55 (0:25)

El programa cambió de plan de estudios en 2018. Una resolución oficial define 72 equivalencias entre cursos, que transcribimos y convertimos en una capa de traducción. El diagrama muestra el primer año: cada curso antiguo, a la izquierda, se traduce a su nombre vigente, a la derecha. Así el sistema funciona con cohortes antiguas, nuevas o mixtas.

Lámina 10 · Antes de desplegar, auditamos · 4:20 (0:40)

Antes de convertir el modelo en herramienta, auditamos nuestro propio diseño y encontramos tres problemas de diseño experimental. Primero, la variable objetivo: el promedio de carrera incluye el primer semestre, que era a la vez el predictor; la reemplazamos por la definición oficial del Reglamento Estudiantil. Segundo, los hiperparámetros se ajustaban mirando también los datos de evaluación; ahora usamos validación anidada. Tercero, las variables se elegían con toda la muestra; ahora se eligen dentro de cada partición. Las dos correcciones siguen recomendaciones conocidas de la literatura, citadas al pie.

Lámina 11 · Cuánto sobreestimaba el resultado cada error · 5:00 (0:35)

Ojo: estos errores no cambian el problema ni el modelo; cambian la medición. Hacen que el modelo parezca mejor de lo que es. Cada barra es cuánto subía el AUC-PR medido con el error frente al medido correctamente. Elegir las variables con toda la muestra lo inflaba 15 puntos; ajustar los hiperparámetros con los datos de evaluación favorecía sobre todo a XGBoost. La línea punteada es nuestro umbral de diferencia relevante.

Lámina 12 · Fase 4 · Objetivo y variables · 5:35 (0:25)

Entramos al modelado. La nueva variable objetivo es la definición oficial: el artículo 19 del Reglamento Estudiantil, que establece cuándo un estudiante pierde su calidad por bajo rendimiento.

Usamos solo seis variables, disponibles al cierre del primer semestre: el promedio de ese semestre, un indicador de si lo cursó, y cuatro puntajes de la prueba Saber 11.

Lámina 13 · Fase 4 · Algoritmos (1 de 2) · 6:00 (0:35)

Cinco algoritmos, de más simple a más complejo. La regresión logística convierte una suma ponderada de las variables en una probabilidad mediante la función sigmoide; el parámetro C controla cuánto se castiga la complejidad. El árbol de decisión divide los datos con preguntas sucesivas, y en cada corte elige la que más reduce la impureza. Random Forest promedia 150 árboles, cada uno entrenado con una muestra distinta y con variables elegidas al azar en cada corte.

Lámina 14 · Fase 4 · Algoritmos (2 de 2) · 6:35 (0:30)

XGBoost también combina árboles, pero en secuencia: cada árbol nuevo corrige los errores del anterior, con una tasa de aprendizaje η y una penalización λ que evita el sobreajuste. La máquina de vectores de soporte busca la frontera de máxima separación, y el kernel radial le permite trazar fronteras curvas. Todas las rejillas tienen entre 16 y 24 combinaciones, para que ningún algoritmo tenga ventaja.

Lámina 15 · Fase 4 · Validación cruzada anidada · 7:05 (0:30)

Así entrenamos y evaluamos. Dividimos a los 80 estudiantes en cinco partes: cuatro entrenan y una evalúa. Dentro de las cuatro de entrenamiento, una segunda validación elige los hiperparámetros. Los 16 estudiantes de evaluación nunca participan en ninguna decisión. Todo se repite diez veces con particiones distintas: obtenemos 50 mediciones por algoritmo, que comparamos con la prueba t corregida de Nadeau y Bengio.

Lámina 16 · Fase 4 · ¿Cuántas variables? · 7:35 (0:15)

¿Cuántas variables necesitamos? Cada punto es un conjunto de variables evaluado con Random Forest. Las seis variables académicas rinden igual que las diecinueve candidatas, y los datos socioeconómicos solos quedan cerca del azar, la línea roja.

Lámina 17 · Fase 4 · Hiperparámetros elegidos · 7:50 (0:20)

Esta gráfica muestra qué hiperparámetros eligió Random Forest en cada una de las 50 particiones. Predominan los árboles poco profundos, de profundidad tres, que usan todas las variables en cada corte: un modelo deliberadamente simple, adecuado para una muestra pequeña.

Lámina 18 · Fase 4 · Importancia de las variables · 8:10 (0:10)

Esta es la importancia por permutación: cuánto cae el desempeño si desordenamos una variable. El promedio del primer semestre domina; las demás aportan poco.

Lámina 19 · Fase 5 · Comparación de algoritmos · 8:20 (0:30)

Pasamos a la evaluación. Usamos el AUC-PR, el área bajo la curva de precisión y exhaustividad, adecuada cuando los casos de interés son pocos. Se lee así: 1 es perfecto, y el azar equivale a la proporción de casos, 0,24, la línea roja. Cada punto es una repetición y el rombo negro, la media. Random Forest obtiene 0,745, tres veces el azar y con poca variación.

Lámina 20 · Fase 5 · Comparaciones pareadas · 8:50 (0:25)

Este mapa compara cada par de algoritmos: la diferencia de AUC-PR y su valor p corregido; en negrita, las diferencias significativas.

Random Forest supera a XGBoost, al árbol y a la regresión logística.

Frente a SVM la diferencia no es significativa, y en ese caso preferimos el modelo más sencillo.

Lámina 21 · Fase 5 · Curvas PR y ROC · 9:15 (0:15)

Las curvas completas confirman el patrón. A la izquierda, precisión frente a exhaustividad; a la derecha, la curva ROC. Random Forest, en azul, se mantiene arriba en casi todo el recorrido.

Lámina 22 · Fase 5 · Matrices de confusión · 9:30 (0:50)

El puntaje de riesgo se convierte en alerta con un umbral, y definimos dos niveles. Cada fila es la realidad y suma cien por ciento; entre paréntesis está el número de estudiantes. En el nivel confirmado, el modelo alerta a 12 de los 19 casos reales, el 63 por ciento, y entre quienes no tuvieron bajo rendimiento solo uno recibe una falsa alarma: el 98 por ciento queda sin alerta. En el nivel de seguimiento se detecta al 79 por ciento de los casos, a cambio de alertar al 39 por ciento de los demás. En un acompañamiento preventivo, una falsa alarma cuesta poco.

Lámina 23 · Fase 5 · Elección del umbral · 10:20 (0:15)

Esta curva muestra el compromiso completo: al subir el umbral aumenta la precisión, en naranja, y disminuyen los casos detectados, en azul. Cuántos estudiantes acompañar lo decide la universidad según su capacidad.

Lámina 24 · Fase 5 · Graduación · 10:35 (0:20)

Repetimos el protocolo para predecir la graduación; aquí el azar es 0,39. SVM obtiene 0,725 y Random Forest 0,705, pero la diferencia no es significativa. Por simplicidad elegimos Random Forest. Esto corrige nuestros resultados preliminares, donde XGBoost aparecía como el mejor.

Lámina 25 · Límite 1 · Casos simultáneos · 10:55 (0:20)

Ahora, los límites, que medimos de forma explícita. El 42 por ciento de los casos ocurre ya en el primer semestre: ahí el modelo confirma, no anticipa. Si evaluamos solo los casos futuros, el desempeño baja a 0,47, pero sigue siendo tres veces el azar.

Lámina 26 · Límite 2 · Calibración · 11:15 (0:10)

Intentamos calibrar las probabilidades con dos métodos. Ninguno mejoró al modelo original, así que el sistema muestra niveles de alerta y no porcentajes.

Lámina 27 · Límite 3 · Semestre a semestre · 11:25 (0:20)

También intentamos predecir semestre a semestre, en tres cortes sucesivos de la carrera. Las barras quedan alrededor de uno, es decir, al nivel del azar. Por eso no desplegamos ese modelo: el seguimiento semestral se hace con las reglas del reglamento.

Lámina 28 · Robustez · Plan 2018 · 11:45 (0:15)

Por último, simulamos que los estudiantes cursaron el plan 2018. El AUC-PR se mantiene entre 0,74 y 0,76, aunque el promedio sube algo más de una décima; los umbrales deberán ajustarse con la primera cohorte real.

Lámina 29 · Fase 6 · TRAYECTA · 12:00 (0:30)

Con lo que superó la auditoría construimos TRAYECTA, un prototipo de seguimiento inspirado en SPADIES del Ministerio de Educación, llevado al nivel de un programa y con las reglas de nuestra universidad. Se carga el extracto académico sin nombres; las equivalencias unifican los planes; se aplican las reglas del reglamento y los dos modelos validados; y el resultado se presenta en pantallas para el equipo académico.

Lámina 30 · Demostración · Panorama · 12:30 (0:30)

Veamos el sistema. Para proteger la privacidad, la demostración usa una cohorte simulada: ningún estudiante es real, pero los modelos sí son los entrenados con los datos reales. Cada punto de la gráfica central es un estudiante, ubicado según su riesgo. Abajo, la situación del reglamento semestre a semestre y la lista de priorización para el equipo de acompañamiento.

Lámina 31 · Demostración · Ficha y carga · 13:00 (0:30)

Al elegir un estudiante se abre su ficha, inspirada en SPADIES: su recorrido semestre a semestre, los créditos aprobados y perdidos, las reglas que se activaron y la comparación de su ingreso con la cohorte. Y al cargar una cohorte nueva, el sistema reconoce el plan de estudios, valida cada código contra el catálogo oficial y advierte si hay planes mezclados.

Lámina 32 · Conclusiones · 13:30 (0:35)

Cuatro conclusiones. Primera: Random Forest es el algoritmo más adecuado para estos datos con un AUC-PR tres veces superior al azar. Segunda: el promedio del primer semestre concentra la información útil. Tercera: con pocos datos, la forma de medir puede cambiar el resultado más que el algoritmo. Y cuarta: la calidad de los datos es determinante. Antes de pensar en el modelo, los datos deben ser confiables, consistentes y relevantes: un buen modelo comienza con buenos datos.

Lámina 33 · Referencias · 14:05 (0:05)

[No se lee; pase a la siguiente lámina tras unos segundos.] Aquí están las referencias que sustentan el trabajo.

Lámina 34 · Límites y siguiente paso · 14:10 (0:35)

Un límite importante: todo proviene de una muestra de 80 estudiantes, sin validación con estudiantes nuevos; es un estudio exploratorio. La curva de aprendizaje aún sube y sugiere un techo cercano a 0,84. Ya solicitamos las cohortes recientes para validar el modelo sin modificarlo, y luego extenderemos el sistema a Ingeniería Electrónica y Biología. Agradecemos al proyecto C07-02-2026-027 y a la Oficina de Sistemas. Muchas gracias; quedo atento a sus preguntas.

Lámina A · Apoyo para preguntas (sin lámina) · anexo (—)

No corresponde a ninguna lámina; es apoyo para la sesión de preguntas. ¿Por qué el reglamento de 2022 si las cohortes estudiaron con el de 2003? Porque es la definición vigente, la que registrará a los estudiantes en quienes se usará el modelo; lo declaramos como supuesto. ¿Es suficiente la muestra? La curva de aprendizaje sigue subiendo; estimamos un techo de 0,84 y que duplicar los datos aportaría unos 5 puntos. ¿Por qué no redes neuronales profundas? Con 80 casos no hay datos suficientes para entrenarlas. ¿Qué significa la variable sin primer semestre? Identifica a quienes ingresaron por homologación al plan 2018; sin ellos el resultado es prácticamente igual, 0,756. ¿Por qué AUC-PR y no exactitud? Porque los casos de riesgo son el 24 por ciento: un modelo que dijera siempre no hay riesgo tendría 76 por ciento de exactitud sin servir para nada. ¿Y la repitencia escolar? A simple

vista se asocia: entre quienes repitieron un año, más del doble perdió la calidad de estudiante. Pero también tienen un promedio de primer semestre más bajo, y una vez que el modelo conoce ese promedio, la repitencia no agrega información distinguible. Con 15 estudiantes que repitieron, no podemos descartar un efecto pequeño; lo evaluaremos con las cohortes nuevas.