

CONTENIDO

INFORMACIÓN GENERAL DEL PROYECTO	1
IDENTIFICACIÓN DE LOS PARTICIPANTES	4
1. INTRODUCCIÓN	5
2. DEFINICIÓN DEL PROBLEMA	6
2.1. Antecedentes del problema	6
2.2. Descripción del problema	8
2.3. Pregunta problema	9
3. JUSTIFICACIÓN	9
4. OBJETIVOS	10
4.1. Objetivo general (OG)	10
4.2. Objetivos específicos (OE)	11
5. MARCO REFERENCIAL	11
5.1. Trayectoria académica estudiantil	11
5.2. Analítica educativa y minería de datos educativos	12
5.3. Aprendizaje automático aplicado a la trayectoria académica	12
5.4. Metodología CRISP-DM	13
5.5. Herramientas tecnológicas	13
6. METODOLOGÍA	14
Etapa 1. Comprensión del negocio y de los datos	14
Etapa 2. Preparación de los datos	15
Compartir el conjunto de datos procesado con el equipo investigador para	16
Etapa 3. Modelado	16
Etapa 4. Evaluación	16
Etapa 5. Documentación y transferencia	17
7. CRONOGRAMA DE ACTIVIDADES	17
8. PRESUPUESTO Y FINANCIACIÓN	18
9. BIBLIOGRAFÍA	19
10. RESULTADOS ESPERADOS	22

MODELO PREDICTIVO DE TRAYECTORIA ACADÉMICA ESTUDIANTIL EN PROGRAMAS DE LA FACULTAD DE CIENCIAS BÁSICAS E INGENIERÍA DE LA UNIVERSIDAD DE LOS LLANOS MEDIANTE APRENDIZAJE AUTOMÁTICO

IDENTIFICACIÓN DE LOS PARTICIPANTES

Estudiante: Joan David Martínez Hernández

Perfil: Estudiante de noveno semestre de Ingeniería de Sistemas de la Universidad de los Llanos. Integrante de los semilleros de investigación Análisis Estadístico (SAES) y Automatic Data-Driven Analytics Laboratory (Adalab). Ganador en la estrategia “Retos de Transformación Digital”, liderada por la Gobernación del Meta, mediante el diseño e implementación de un sistema de gestión de órdenes de trabajo para el sector óptico (2025). Con bases en desarrollo web, especialmente en backend, utilizando Java y el framework Spring Boot. Código estudiantil: 160004716. Email: joan.martinez@unillanos.edu.co

Directora: Ing. Diana Marcela Cardona Román, M.Sc, Ph.D

Perfil: Ingeniera de Sistemas de la Universidad de los Llanos, Magíster en Ingeniería de Sistemas y Computación y Doctora en Ingeniería - Industria y Organizaciones de la Universidad Nacional de Colombia, Sede Bogotá (Becaria 2013-2018 Conv. 567/2012 formación de doctorado nacional). Postdoc 2021-2022 Fundación Cardiovascular de Colombia (FCV) - Universidad Corporativa (Conv. 891 de 2020 Mecanismo 2 MinCiencias). Reconocida como par evaluadora de MinCiencias. Investigadora visitante en la Universidad Oberta de Catalunya (UOC) de Barcelona-España, en CEPADE de la Universidad Politécnica de Madrid en Madrid-España y en la Universidad Autónoma de Baja California (UABC) en Tecate-México. Investigadora y colaboradora en los grupos de investigación GRIEGO (Grupo de investigación en Gestión Organizacional - Categoría A1 - MinCiencias) de la Universidad Nacional de Colombia y actualmente, miembro del grupo de Investigación GITECX (Categoría C - MinCiencias) de la Universidad de los Llanos. Ha dirigido trabajos de grado en pregrado y maestría, igualmente ha sido jurado de trabajos de pregrado, maestría y propuestas doctorales. Ha escrito capítulos de libro y artículos científicos para revistas indexadas, *working papers* y eventos académicos nacionales e internacionales, entre otros. Actualmente está vinculada como profesora de planta de la Universidad de los Llanos en la Facultad de Ciencias Básicas e Ingeniería. Tiene a cargo de los cursos Lenguajes de programación e Introducción a la analítica de datos. Email: dcardona@unillanos.edu.co.

Codirectora: Sara Cristina Guerrero, Ph.D.

Perfil: Doctora en Ciencias de la Educación. Magister en Ciencias Estadísticas, Licenciada. Área de experticia: análisis estadístico, deserción universitaria y trayectoria académica en educación superior. Investigadora principal del proyecto longitudinal “Estudio de la trayectoria estudiantil en los programas de la FCBI con énfasis en las dimensiones STEM” (C07-02-2026-027. Miembro del Grupo de Investigación Sistemas Dinámicos - GISD (Categoría C — MinCiencias), Facultad de Ciencias Básicas e Ingeniería, Líder del Semillero de Análisis Estadístico (SAES) de la Universidad de los Llanos. Email: sguerrero@unillanos.edu.co

1. INTRODUCCIÓN

La deserción y el rezago estudiantil constituyen uno de los desafíos más relevantes que enfrentan las instituciones de educación superior (IES) en América Latina. En Colombia, la tasa promedio de abandono por cohorte en educación superior se ubica alrededor del 45,3% [1], y asciende en el área de conocimiento que agrupa las ingenierías, las matemáticas y las ciencias naturales [1], es decir, los programas STEM (Science, Technology, Engineering and Mathematics). La Facultad de Ciencias Básicas e Ingeniería (FCBI) de la Universidad de los Llanos no es ajena a esta problemática: en algunas cohortes de sus programas de Ingeniería de Sistemas, Ingeniería Electrónica y Biología, las tasas de abandono superan el 70% [1], [2]. Estas cifras ponen de manifiesto la necesidad de comprender los factores que inciden en la trayectoria académica de los estudiantes y de desarrollar mecanismos que permitan anticipar situaciones de riesgo desde los primeros semestres.

Para abordar este tipo de problemáticas, la analítica educativa (*Learning Analytics*) y la minería de datos educativos (*Educational Data Mining*) se han consolidado como disciplinas que permiten aprovechar los registros históricos de las instituciones para generar evidencia útil en la toma de decisiones académicas e institucionales [3]. En particular, el aprendizaje automático (machine learning) ofrece técnicas de clasificación y predicción que, a partir de datos de cohortes existentes, posibilitan la construcción de modelos capaces de identificar qué estudiantes presentan mayor probabilidad de deserción, rezago o dificultades en su trayectoria académica [4], [5]. La aplicación de estas técnicas en el contexto universitario ha mostrado resultados prometedores a nivel internacional [4], [6], aunque su adopción en instituciones de la región, y en particular en la Orinoquia colombiana, aún es incipiente.

En este marco, la presente propuesta plantea el desarrollo de un modelo predictivo de trayectoria académica para los programas STEM de la FCBI de la Universidad de los Llanos, empleando técnicas de aprendizaje automático y siguiendo la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) [7]. Esta propuesta se articula con el proyecto de investigación titulado “Estudio de la trayectoria estudiantil en los programas de la FCBI con énfasis en las dimensiones STEM” [8],.

2. DEFINICIÓN DEL PROBLEMA

2.1. Antecedentes del problema

La deserción universitaria es un fenómeno ampliamente documentado alrededor del mundo, con tasas promedio cercanas al 31% en países de la OCDE, entre sus miembros, los que presentan mayores niveles de deserción son: Hungría, Nueva Zelanda y Estados Unidos, siendo Nueva Zelanda el país que alcanza el porcentaje más alto, con un 46%; a diferencia de aquellos con menor tasa de deserción como Japón, Alemania, Francia y Bélgica [9]. A nivel regional, la tasa promedio de abandono en educación superior supera el 50% [10], mientras que en Colombia la tasa media de abandono por cohorte en educación superior se ubica alrededor del 45,3% [1]. Esta cifra asciende al 51% cuando se considera específicamente el área de conocimiento de ingeniería, arquitectura, matemáticas y ciencias naturales [1], que agrupa los programas STEM objeto de este estudio.

En la Universidad de los Llanos, la situación es aún más crítica: para la cohorte del primer semestre de 2017, la tasa de abandono en la FCBI alcanzó el 50,6 %, y en los programas de Ingeniería de Sistemas, Ingeniería Electrónica y Biología llegó al 70,21 % [1], [2]. Adicionalmente, el Ministerio de Educación Nacional estima que un estudiante tarda en promedio 14 semestres en graduarse, cuando el plan curricular prevé sólo 10 [1], lo que evidencia un rezago sistemático que agrava la problemática.

En la literatura revisada se pueden encontrar cuatro grandes tipos de factores asociados a la deserción y el rezago: académicos, económicos, institucionales y personales [10], [11]. Se ha demostrado, a través de estudios recientes, que variables sociodemográficas (género, estrato socioeconómico, municipio de procedencia) y académicas (promedio de ingreso, carga

académica, reprobación de asignaturas del ciclo básico) explican de forma significativa la trayectoria estudiantil [12], [13]. Sin embargo, el análisis de estos factores en la FCBI se ha llevado a cabo mediante herramientas estadísticas de propósito general que no permiten la construcción de modelos predictivos automatizables ni generalizables a nuevas cohortes.

Las técnicas estadísticas que se han utilizado para describir y analizar el abandono del estudiante son el análisis de supervivencia, los modelos de riesgos competitivos y la regresión logística multivariable [12], [14]. Estas aproximaciones, si bien permiten cuantificar la influencia de factores individuales, tienen limitaciones para capturar interacciones complejas entre variables y para escalar a grandes volúmenes de datos. Por ello, el uso de algoritmos de aprendizaje automático ha cobrado creciente relevancia para la predicción del abandono universitario, ya que estos modelos pueden identificar patrones no lineales y relaciones multifactoriales que no son fácilmente detectables a través de métodos clásicos [4], [5], [6].

En la región de Oriente Medio y Norte de África (MENA), Al Hashmi et al. [15] utilizaron técnicas de inteligencia artificial explicable para predecir la deserción en los programas STEM de educación superior, empleando algoritmos como Random Forest y XGBoost junto con valores SHapley Additive ExPlanation (SHAP) para interpretar las predicciones; los resultados de su estudio destacaron la importancia de las variables del rendimiento académico temprano como predictores clave de la deserción. Mendes Rabelo y Zárate [16] propusieron, por su parte, un modelo ensamblado que combina regresión logística, redes neuronales y árboles de decisión para predecir la deserción en educación superior, con una exactitud del 89 % y identificando correctamente al 98,1 % de los estudiantes desertores; este estudio evidencia las ventajas de los métodos de ensamble frente a los clasificadores individuales. En un contexto más cercano al colombiano, Peralta-Fragozo y Hoyos-Sánchez [17] desarrollaron un marco basado en aprendizaje automático para la identificación temprana de estudiantes en riesgo, utilizando variables académicas, socioeconómicas y demográficas; mediante técnicas de sobremuestreo (SMOTE) y algoritmos como Random Forest y SVM, obtuvieron valores de AUC superiores a 0,94, confirmando la viabilidad de estos enfoques para sistemas de monitoreo proactivo en instituciones de educación superior.

Respecto al estudio de trayectorias académicas, trabajos como el de Martínez-González et al. [18] han evidenciado que el análisis de la secuencia de eventos académicos: aprobación, reprobación, rezago y abandono, permite construir perfiles de riesgo más precisos que los que se obtienen a partir de indicadores de corte transversal. La combinación de estos análisis de trayectoria con modelos predictivos de machine learning es un enfoque prometedor que potencia la capacidad de anticipación institucional [12], [13].

Finalmente, la traducción de estos modelos predictivos a herramientas de software funcionales es fundamental para cerrar la brecha entre la investigación analítica y la toma de decisiones institucionales. Investigaciones como la de Delen [19] han demostrado que la construcción de sistemas de soporte a la decisión basados en machine learning permite a las instituciones de educación superior implementar intervenciones tempranas y focalizadas sobre los estudiantes en riesgo. En la misma línea, el proyecto longitudinal de la FCBI [8] incluye la integración del modelo predictivo en una plataforma de software institucional, lo cual refuerza la necesidad de abordar no solo el componente analítico sino también la construcción tecnológica que habilite su despliegue y uso operativo.

2.2. Descripción del problema

El proyecto de investigación longitudinal “Estudio de la trayectoria estudiantil en los programas de la FCBI con énfasis en las dimensiones STEM” [8] ha recopilado bases de datos académicas y sociodemográficas de los estudiantes matriculados en las cohortes 2017-2 y 2018-1 en los programas de Ingeniería de Sistemas, Ingeniería Electrónica y Biología. Esta información, de alto valor analítico, puede potenciarse mediante el uso de técnicas avanzadas y el desarrollo de un(os) modelo(s) predictivo(s) capaz(ces) de identificar a los estudiantes en riesgo, así como de anticipar el comportamiento académico de nuevos estudiantes con base en los patrones identificados en cohortes objeto de estudio.

La no visibilización de dicho modelo representa una brecha concreta en la capacidad institucional de la FCBI. Como señalan Trespalacios Arismendi et al. [20] en un trabajo en progreso sobre minería de datos para la predicción de la deserción en la misma facultad, la aplicación de la metodología CRISP-DM junto con algoritmos de aprendizaje automático (como árboles de decisión y redes neuronales) ofrece el potencial de identificar patrones predictivos y

revelar correlaciones entre factores de deserción que no son visibles mediante métodos estadísticos tradicionales. Sin embargo, dicho trabajo se centra en la caracterización de la deserción durante el periodo 2017–2022 y aún se encuentra en fase de preparación de datos; no aborda la predicción de la trayectoria académica completa (permanencia, rezago y graduación) ni la construcción de un modelo validado y transferible para su integración en una plataforma de software institucional. El presente proyecto retoma y complementa esa línea de trabajo, con el objetivo de construir un modelo predictivo funcional que permita anticipar el comportamiento académico de los nuevos estudiantes a partir de los patrones observados en las cohortes 2017-2 y 2018-1, cerrando así la brecha entre el análisis descriptivo y la toma de decisiones basada en evidencia en la FCBI.

2.3. Pregunta problema

¿Cuál algoritmo de aprendizaje automático ofrece el mejor desempeño predictivo de la trayectoria académica de los estudiantes de la FCBI?

3. JUSTIFICACIÓN

El desarrollo de un modelo de *machine learning* de trayectoria académica para la FCBI se justifica desde tres perspectivas complementarias.

Desde el punto de vista de la **Ingeniería de Sistemas**, el proyecto aplica de manera integrada competencias fundamentales del programa académico: ingeniería de datos, aprendizaje automático, evaluación y validación de modelos e interpretación de resultados en contextos reales. Es importante resaltar que, si bien algunas técnicas como la regresión logística se utilizan tanto en estadística clásica como en aprendizaje automático, el objetivo y el flujo de trabajo difieren sustancialmente [21], [22]. En el enfoque estadístico tradicional, la regresión logística se emplea como modelo inferencial, estimándose los coeficientes (odds ratios), evaluando pruebas de significancia (prueba de Wald, p-values) y verificando la bondad de ajuste (prueba de Hosmer-Lemeshow), con el objetivo de explicar por qué ocurre un fenómeno y cuantificar la influencia de cada variable. Por el contrario, en el contexto de ML la misma técnica se utiliza como clasificador baseline y se somete a un pipeline de validación cruzada, split train/test y optimización de hiperparámetros, donde se prioriza la capacidad predictiva y de generalización a datos no vistos [22]. Los algoritmos de ML como Random Forest, XGBoost o redes neuronales

aportan, además, la capacidad de capturar automáticamente interacciones no lineales y relaciones multifactoriales que los modelos estadísticos lineales no detectan fácilmente, lo que resulta particularmente relevante cuando se trabaja con variables académicas y sociodemográficas heterogéneas [4], [5]. El uso de la metodología CRISP-DM [7] garantiza un proceso sistemático, reproducible y orientado al despliegue futuro, lo que diferencia este trabajo de un análisis estadístico convencional y lo sitúa en el campo de los sistemas de soporte a la decisión basados en datos.

Desde la **perspectiva de la investigación educativa y la política institucional**, el modelo predictivo propuesto tiene el potencial para facilitar el análisis de la trayectoria académica de los programas de la FCBI identificando los tiempos de permanencia y graduación y los estudiantes en riesgo [23]. Las instituciones que adoptan enfoques de analítica del aprendizaje logran intervenciones más oportunas y basadas en evidencia [24]. En el contexto colombiano, donde los procesos de acreditación de alta calidad exigen evidencia cuantitativa sobre la efectividad de las estrategias de permanencia [2], [12], contar con un modelo validado constituye un aporte directo a los procesos de evaluación y mejora continua de la facultad.

Desde la **perspectiva de los beneficiarios**, el modelo servirá como insumo para la Decanatura, los Comités Curriculares de la FCBI y en general, cualquier dependencia que requiera el análisis de la trayectoria académica, facilitando la identificación temprana de cohortes con alto riesgo de deserción y el diseño de estrategias de intervención focalizadas. Así mismo, los datos procesados y el modelo resultante serán compartidos como insumos al grupo investigador, garantizando la complementariedad y reutilización de los productos.

Sin la ejecución de este proyecto, el valioso acervo de datos académicos y sociodemográficos recopilado por el equipo investigador continuará siendo analizado de forma descriptiva, sin capacidad predictiva, perdiendo la oportunidad de anticipar fenómenos que tienen consecuencias personales, sociales e institucionales significativas.

4. OBJETIVOS

4.1. Objetivo general (OG)

- Comparar algoritmos de aprendizaje automático para la predicción de la trayectoria académica de los estudiantes de la FCBI de la Universidad de los Llanos con el fin de

apoyar la identificación de factores asociados a la permanencia, el riesgo de deserción y el rezago.

4.2. Objetivos específicos (OE)

- Caracterizar las trayectorias a partir de la consolidación de un conjunto de datos académicos y sociodemográficos de las cohortes 2017-2 y 2018-1 de la FCBI, aplicando procesos de comprensión, integración, limpieza y transformación de datos.
- Implementar algoritmos de aprendizaje automático para modelar la trayectoria académica de los estudiantes de la FCBI, configurando los hiperparámetros necesarios.
- Evaluar y comparar el desempeño de los modelos predictivos entrenados mediante métricas estándar de clasificación que permitan seleccionar el modelo de mayor capacidad predictiva con la interpretación de las variables más relevantes para la gestión institucional.

5. MARCO REFERENCIAL

5.1. Trayectoria académica estudiantil

La trayectoria académica se define como el recorrido de un estudiante desde su ingreso hasta la culminación de sus estudios en la educación formal [25]. Bravo Guerrero et al. [26] distinguen dos dimensiones: la *trayectoria ideal*, determinada por los créditos planificados en el plan curricular para cada periodo, y la *trayectoria real*, que refleja el ritmo efectivo al que los estudiantes aprueban los créditos. El análisis comparativo de ambas dimensiones permite identificar fenómenos como el rezago, la repitencia y la deserción.

La literatura indica que los programas con mayor énfasis en competencias matemáticas presentan tasas de abandono particularmente altas [2]. Castro-Montoya et al. [11] identifican que variables como el promedio de ingreso, el estrato socioeconómico y la carga académica inicial tienen poder explicativo significativo sobre la graduación, la deserción y el rezago en programas de pregrado colombianos. Los estudios longitudinales constituyen la aproximación metodológica más adecuada para comprender este fenómeno, pues permiten identificar patrones de cambio y secuencias de eventos a lo largo del tiempo [27].

En el contexto de las carreras STEM, investigaciones recientes resaltan el papel del género [28], las expectativas iniciales de los estudiantes [29] y la progresión en asignaturas de ciencias básicas [13] como factores diferenciadores de la trayectoria. Li, Kirk y Oseguera [30] subrayan la importancia estratégica de estas carreras para la competitividad científica y tecnológica, lo que refuerza el valor social de intervenir oportunamente en favor de la permanencia estudiantil.

5.2. Analítica educativa y minería de datos educativos

El término *Learning Analytics* (LA) fue acuñado formalmente en la primera conferencia LAK (2011) como la medición, recopilación, análisis y reporte de datos sobre los estudiantes y sus contextos, con el propósito de comprender y optimizar el aprendizaje y los entornos en que ocurre [31]. La minería de datos educativos (*Educational Data Mining*, EDM), campo complementario, se centra en el desarrollo de métodos computacionales para descubrir patrones en grandes conjuntos de datos académicos [3].

Ambos campos han demostrado eficacia en la predicción de la deserción, la identificación de estudiantes en riesgo y la evaluación de la efectividad curricular [3], [13]. A nivel nacional, el Sistema para la Prevención de la Deserción en la Educación Superior (SPADIES) del Ministerio de Educación Nacional [1] constituye la herramienta gubernamental de referencia, aunque sus indicadores son agregados a nivel institucional y no permiten análisis predictivos personalizados a nivel de programa o cohorte.

5.3. Aprendizaje automático aplicado a la trayectoria académica

El aprendizaje automático (*machine learning*) comprende un conjunto de algoritmos que aprenden patrones a partir de datos históricos para realizar predicciones o clasificaciones sobre nuevas observaciones [21]. Los modelos de aprendizaje automático se clasifican en tres grandes paradigmas según la forma en que aprenden de los datos [21], [22]:

- **Aprendizaje supervisado:** el modelo se entrena con un conjunto de datos etiquetados, donde cada observación tiene asociada una respuesta conocida. Incluye tareas de *clasificación* (predecir una categoría discreta) y *regresión* (predecir un valor continuo). Este es el paradigma empleado en el presente proyecto, dado que la variable objetivo, el estado académico del estudiante (graduado, activo, desertor, rezagado), es categórica [4].

- **Aprendizaje no supervisado:** el modelo trabaja con datos no etiquetados e identifica estructuras ocultas, como agrupamientos (*clustering*) o reducción de dimensionalidad [21].
- **Aprendizaje por refuerzo:** un agente aprende a tomar decisiones mediante un sistema de recompensas y penalizaciones al interactuar con un entorno [32].

Algoritmos de clasificación supervisada

Dentro del aprendizaje supervisado, los algoritmos de clasificación más empleados para predecir la trayectoria académica son los siguientes [4], [5]:

- **Regresión logística (LR):** modelo lineal generalizado que estima la probabilidad de pertenencia a una clase. Es ampliamente utilizado como clasificador de línea base (*baseline*) por su alta interpretabilidad y simplicidad [21].
- **Árboles de decisión (DT):** realizan particiones recursivas del espacio de atributos mediante reglas condicionales, generando estructuras fácilmente interpretables.
- **Random Forest (RF):** método de ensamble tipo *bagging* que construye múltiples árboles de decisión con muestreo aleatorio de muestras y atributos, y combina sus predicciones por votación mayoritaria. Es robusto frente al sobreajuste y maneja eficazmente datos heterogéneos [33].
- **XGBoost / Gradient Boosting:** métodos de ensamble tipo *boosting* que construyen árboles de forma secuencial, donde cada nuevo árbol corrige los errores residuales del anterior. XGBoost incorpora, además, técnicas de regularización (L1 y L2) que mejoran la generalización [34].
- **Máquina de Vectores de Soporte (SVM):** busca el hiperplano que maximiza el margen de separación entre clases; mediante funciones kernel puede manejar fronteras de decisión no lineales.
- **Redes neuronales artificiales (MLP):** perceptrón multicapa con retropropagación, capaz de modelar relaciones altamente no lineales entre variables de entrada y salida [21].

Hiperparámetros

El rendimiento de los modelos de aprendizaje automático depende en gran medida de la configuración de sus hiperparámetros, es decir, parámetros que no se aprenden directamente

de los datos sino que se definen antes del entrenamiento. A continuación se describen los hiperparámetros más relevantes de los tres algoritmos que la literatura identifica como más efectivos en este dominio [15], [17]:

Random Forest [33]:

- `n_estimators`: número de árboles en el bosque; un valor mayor mejora la estabilidad pero incrementa el costo computacional.
- `max_depth`: profundidad máxima de cada árbol; controla la complejidad del modelo y previene el sobreajuste.
- `min_samples_split` / `min_samples_leaf`: número mínimo de muestras requerido para dividir un nodo o para existir en una hoja.
- `max_features`: número de atributos considerados en cada partición.

XGBoost [34]:

- `learning_rate` (`eta`): tamaño del paso en cada iteración; valores pequeños mejoran la robustez pero requieren más estimadores.
- `max_depth`: profundidad máxima de cada árbol reforzado.
- `n_estimators`: número total de árboles secuenciales.
- `subsample` / `colsample_bytree`: fracción de observaciones y atributos muestreados para cada árbol, lo que previene el sobreajuste.
- `gamma`, `lambda` (L2), `alpha` (L1): parámetros de regularización que penalizan la complejidad del modelo.

Redes neuronales (MLP) [21]:

- `hidden_layer_sizes`: arquitectura de la red, es decir, número de capas ocultas y neuronas por capa.
- `learning_rate` / `optimizer`: controlan la velocidad y el algoritmo de actualización de pesos (e.g., Adam, SGD).
- `batch_size` / `epochs`: cantidad de datos procesados antes de actualizar los pesos y número total de pasadas por el conjunto de entrenamiento.
- `dropout_rate`: técnica de regularización que desactiva aleatoriamente neuronas durante el entrenamiento para prevenir el sobreajuste.

La optimización de hiperparámetros se realiza comúnmente mediante búsqueda en cuadrícula (*grid search*), búsqueda aleatoria (*random search*) u optimización bayesiana (e.g., Optuna), siempre combinada con validación cruzada estratificada para garantizar la robustez de los resultados [35].

Métricas de evaluación

Las métricas de evaluación permiten comparar objetivamente el desempeño de los modelos de clasificación. Las más empleadas en el dominio de la predicción de la trayectoria académica son [4], [21]:

- **Exactitud (*accuracy*)**: proporción de predicciones correctas sobre el total de observaciones. Es útil cuando las clases están balanceadas, pero puede ser engañosa en presencia de desbalanceo de clases.
- **Precisión (*precision*)**: de todos los estudiantes clasificados como “en riesgo”, ¿cuántos realmente lo están? Mide la proporción de verdaderos positivos entre todas las predicciones positivas.
- **Exhaustividad (*recall* o *sensibilidad*)**: de todos los estudiantes que realmente están en riesgo, ¿cuántos fueron detectados por el modelo? Esta métrica es *crítica* en sistemas de alerta temprana, donde no detectar a un estudiante en riesgo tiene un costo institucional y social elevado.
- **F1-score**: media armónica de la precisión y la exhaustividad. Es especialmente adecuada cuando existe desbalanceo de clases, ya que penaliza modelos que sacrifican una métrica en favor de la otra. En el presente proyecto, donde se espera que la clase “desertor” sea minoritaria frente a “graduado” o “activo”, el F1-score constituye una de las métricas principales de evaluación.
- **AUC-ROC (Área bajo la curva ROC)**: mide la capacidad discriminativa global del modelo a través de todos los umbrales de clasificación. Un valor de 1,0 indica discriminación perfecta y 0,5 equivale a una clasificación aleatoria. Es una métrica robusta frente al desbalanceo de clases y permite comparar modelos de forma independiente del umbral seleccionado.

Dado el desbalanceo esperado entre las clases de la variable objetivo en las cohortes de la FCBI (pocos desertores frente a una mayoría de graduados y activos), el **F1-score** y el **AUC-ROC** son las métricas más apropiadas para este proyecto [15], [17].

Evidencia empírica en la literatura

Hellas et al. [4] realizaron una revisión sistemática de modelos predictivos del desempeño estudiantil en educación superior, identificando que los modelos de árbol de decisión, bosque aleatorio (*random forest*) y regresión logística son los más frecuentemente empleados por su interpretabilidad y buen desempeño. Mduma et al. [5] comparan múltiples algoritmos para la predicción de la deserción en contextos africanos y reportan que los ensambles de modelos (*ensemble methods*) superan consistentemente a los clasificadores individuales. Sotomayor et al. [6] aplican estas técnicas en el contexto latinoamericano con datos de universidades colombianas, confirmando la viabilidad y pertinencia del enfoque para instituciones de la región.

En estudios más recientes que reportan métricas cuantitativas detalladas, Al Hashmi et al. [15] evaluaron seis clasificadores supervisados para predecir la deserción en programas STEM en la región MENA, encontrando que XGBoost, Gradient Boosting Machine y Random Forest obtuvieron valores de AUC-ROC superiores a 0,91 y F1-scores por encima de 0,84. Mendes Rabelo y Zárate [16] propusieron un modelo ensamblado que combina regresión logística, redes neuronales y árboles de decisión, alcanzando una exactitud del 89 % y una exhaustividad del 98,1 % para la clase de desertores. Peralta-Fragozo y Hoyos-Sánchez [17] obtuvieron un AUC de 0,958 y un G-Mean de 0,89 con un Balanced Random Forest Classifier, confirmando la efectividad de los ensambles basados en árboles para datos con desbalanceo de clases. Delen [19], en su estudio, demostró que los modelos de ensamble superan consistentemente a los clasificadores individuales (DT, NN, SVM) en la gestión de retención estudiantil, con exactitudes superiores al 80 % utilizando datos balanceados.

Adicionalmente, Realinho et al. [36] publicaron un conjunto de datos de referencia (*benchmark*) del Instituto Politécnico de Portalegre (Portugal), con 4.424 registros de estudiantes clasificados en tres categorías (graduado, desertor, matriculado), acompañado de un análisis exploratorio con múltiples algoritmos de clasificación. Iam-On y Boongoen [37] propusieron un enfoque de ensamble basado en clustering de datos mixtos para la predicción de la deserción en universidades tailandesas, reportando una exactitud cercana al 80,5 % con Random Forest y un AUC de 0,89 con XGBoost. Martins et al. [38] extendieron el trabajo de Realinho et al. mediante una predicción multifase del rendimiento académico y la deserción en educación superior, evaluando más de diez algoritmos, incluyendo Random Forest, XGBoost, LightGBM, CatBoost, SVM y regresión logística y reportando una exactitud máxima de 0,78 con Random Forest y

F1-scores entre 0,76 y 0,87 según la clase evaluada. Finalmente, Bañeres et al. [39] diseñaron un sistema de inteligencia para el aprendizaje (Learning Intelligence System) en la Universitat Oberta de Catalunya, orientado a la identificación e intervención temprana de estudiantes en riesgo de abandono en programas en línea, alcanzando valores de AUC superiores a 0,95 mediante modelos de ensamble.

La tabla 1 compara los resultados cuantitativos reportados por los estudios que incluyen métricas de desempeño detalladas, organizados por métrica: exactitud (accuracy), F1-score y AUC-ROC, respectivamente. Las celdas con “—” indican que el estudio no reportó dicha métrica para el algoritmo correspondiente.

Tabla 1.Comparación de métricas como Accuracy, F1-score y AUC-ROC reportadas por estudio y algoritmo.

Algoritmo	Al Hashmi et al. [15]	Mendes R. y Zárata [16]	Peralta-F. y Hoyos-S. [17]	Delen [19]	Realinho et al. [36]	Iam-On y Boongoe n [37]	Martins et al. [38]	Bañeres et al. [39]
Random Forest	--- F1-Score = >0,84 AUC-ROC = >0,91	Accuracy = 0,89 —	--- — AUC-ROC = 0,958	Accuracy =>0,80	Accuracy =0,76 F1-Score= 0,73 AUC-ROC =0,83	Accuracy =0,805	Accuracy =0,78 F1-Score= 0,76--0,87 AUC-ROC = 0,85	---
XGBoost / GB	--- F1-Score = >0,84 AUC-ROC = >0,91	---	---	---	Accuracy =0,74 F1-Score=0,71 AUC-ROC = 0,82	--- F1-Score=0,77 AUC-ROC = 0,89	Accuracy =0,77 F1-Score=0,75--0,85 AUC-ROC = 0,84	---
Regresión logística	---	Accuracy = 0,89	---	---	Accuracy =0,72 F1-Score=0,68 AUC-ROC = 0,78	---	Accuracy =0,74 F1-Score= 0,70--0,80 AUC-ROC = 0,80	---

Árboles de decisión	---	Accuracy =0,89	---	Accuracy =>0,80	Accuracy =0,70 F1-Score=0,65 AUC-ROC =0,72	---	Accuracy =0,72 F1-Score= 0,68--0,78 AUC-ROC = 0,75	---
SVM	---	---	--- — AUC-ROC = >0,94	---	Accuracy =0,71 F1-Score=0,67 AUC-ROC =0,77	---	Accuracy =0,73 F1-Score= 0,69--0,79 AUC-ROC = 0,79	---
Redes neuronales	---	Accuracy =0,89	---	Accuracy =>0,80	---	---	---	---
Ensamble combinado	--- — AUC-ROC >0,91	Accuracy =0,89	--- F1-Score = 0,89* AUC-ROC = 0,958	---	---	---	---	Accuracy =>0,85 F1-Score: >0,80 AUC-ROC: >0,95

*G-Mean reportado como medida de equilibrio entre clases

El análisis de los resultados de la Tabla 1 confirma que los métodos de ensamble basados en árboles, en particular Random Forest y XGBoost/Gradient Boosting, obtienen de forma consistente los mejores valores en las tres métricas evaluadas, lo que respalda su selección como algoritmos candidatos en la etapa de modelado del presente proyecto.

5.4. Herramientas tecnológicas

El proyecto emplea las siguientes tecnologías, seleccionadas por su madurez, documentación y adopción en ciencia de datos y analítica educativa:

- **Microsoft Power BI [40]:** para las fases de comprensión y preparación de datos (fases 1–3 de CRISP-DM), permitiendo exploración visual rápida de la distribución y calidad de las variables.

- **Python 3.10+ [41]:** lenguaje principal para el modelado y la evaluación (fases 4–5 de CRISP-DM), con las bibliotecas scikit-learn [35], Pandas [42] e Imbalanced-learn para el manejo de clases desbalanceadas.
- **Jupyter Notebook:** entorno interactivo de desarrollo, documentación y reproducibilidad del proceso de modelado.
- **Git/GitHub:** sistema de control de versiones para el código fuente y los artefactos del modelo.

6. METODOLOGÍA

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) es la metodología estándar de la industria para proyectos de minería de datos y aprendizaje automático [10]. Define un proceso iterativo de seis fases: (1) comprensión del negocio, (2) comprensión de los datos, (3) preparación de los datos, (4) modelado, (5) evaluación y (6) despliegue. Esta metodología fue seleccionada frente a alternativas como KDD porque incorpora desde su diseño la perspectiva del despliegue y la reutilización del modelo, lo que resulta pertinente dado que el sistema final deberá integrarse con la plataforma de software del proyecto longitudinal. Chapman et al. [43] documentan su aplicación en proyectos industriales, y Schröer et al. [44] demuestran su idoneidad específica para proyectos de analítica educativa.

El proyecto sigue la metodología CRISP-DM [7], [43], adaptada al contexto académico de la FCBI. El proceso es iterativo: los resultados de fases posteriores pueden requerir volver a fases anteriores para refinar la comprensión del problema o mejorar la preparación de los datos. Se definen cinco etapas de desarrollo, cada una alineada con los objetivos específicos del proyecto.




Figura 1. Proceso CRISP-DM adaptado al proyecto de trayectoria académica FCBI, basado en el ciclo de vida de minería de datos propuesto por IBM [45].

Etapa 1. Comprensión del negocio y de los datos

Esta etapa corresponde a las fases 1 y 2 de CRISP-DM. Se busca comprender el contexto institucional del problema y caracterizar las fuentes de datos disponibles.

Actividades:

- Revisión de la literatura sobre trayectoria académica, analítica educativa y modelos predictivos en educación superior.
- Delimitar el problema de predicción: definición de la variable objetivo (estado académico al final del seguimiento: graduado, activo, desertor, rezagado), horizonte temporal y unidad de análisis.

- Solicitud, recepción e inventario de las bases de datos académicas y sociodemográficas de las cohortes 2017-2 y 2018-1, suministradas por las dependencias de la Universidad (Registros Académicos, Bienestar Universitario, Planeación).
- Exploración visual de los datos mediante Power BI: distribuciones de variables, valores faltantes, consistencia de registros y primeros patrones por programa, género, estrato y cohorte.
- Documentación del diccionario de datos y el catálogo de fuentes.

Entregable: Documento de comprensión del negocio y diccionario de datos.

Etapas 2. Preparación de los datos

Esta etapa corresponde a la fase 3 de CRISP-DM y produce el conjunto de datos listos para el modelado.

Actividades:

- Depuración de datos: tratamiento de valores faltantes (imputación o exclusión justificada), eliminación de duplicados y corrección de inconsistencias.
- Integración de las fuentes de datos: cruce de registros académicos con variables sociodemográficas a partir del identificador estudiantil.
- Transformación y codificación de variables categóricas; normalización y estandarización de variables numéricas según los requerimientos de los modelos a emplear.
- Análisis del desbalance de clases en la variable objetivo y selección de estrategia de tratamiento (*oversampling*, *undersampling* o pesos de clase).
- Partición del conjunto de datos en subconjuntos de entrenamiento, validación y prueba.
- **Compartir el conjunto de datos procesado con el equipo investigador** para el inicio paralelo del desarrollo de la plataforma de software del proyecto longitudinal.

Entregable: Conjunto de datos procesado y documentado (formato .csv / .xlsx), listo para modelado.

Etapla 3. Modelado

Esta fase se corresponde con la fase 4 de CRISP-DM. Se eligen, se configuran y se entrenan los modelos de aprendizaje automático candidatos. La selección de los algoritmos se basa en el análisis comparativo de la evidencia empírica presentada en la sección 5.3.5, donde las Tablas 1, 2 y 3 resumen los resultados de exactitud, F1-score y AUC-ROC reportados por ocho estudios de referencia [15], [16], [17], [19], [36], [37], [38], [39]. El análisis realizado confirma que los métodos de ensamble basados en árboles, en especial Random Forest y XGBoost/Gradient Boosting, obtienen consistentemente los valores más altos en las tres métricas evaluadas, por lo que resulta justificada su inclusión como algoritmos candidatos principales. Incluimos también la regresión logística como línea base interpretable, árboles de decisión individuales, SVM y opcionalmente redes neuronales para abarcar un espectro amplio de familias algorítmicas y así asegurar una comparación rigurosa.

Actividades:

- Se seleccionan como algoritmos candidatos regresión logística (línea base), árbol de decisión, bosque aleatorio (random forest), máquina de vectores de soporte (SVM) y gradient boosting (XGBoost) con base en la revisión de literatura [4], [5], sin embargo, se deja abierta la posibilidad de probar otros algoritmos que puedan ayudar a resolver el problema.
- Entrenamiento de cada modelo sobre el subconjunto de entrenamiento, con ajuste de hiperparámetros, se probará un enfoque de búsqueda en cuadrícula (*grid search*) y en caso de requerirse se podrá realizar validación cruzada.
- Análisis de la importancia de variables (*feature importance*) para identificar los predictores más relevantes de la trayectoria académica.

Entregable: Repositorio de modelos entrenados con código documentado en Jupyter Notebook y Python.

Etapla 4. Evaluación

Esta etapa corresponde a la fase 5 de CRISP-DM. Se comparan y validan los modelos entrenados.

Actividades:

- Evaluación de todos los modelos candidatos sobre el subconjunto de prueba mediante exactitud, precisión, exhaustividad (*recall*), F1-score y AUC-ROC por clase.
- Selección del modelo de mejor desempeño global, considerando tanto las métricas técnicas como la interpretabilidad de sus predicciones.
- Análisis e interpretación de las variables con mayor poder predictivo en términos de su pertinencia institucional (¿qué factores identifican a los estudiantes en riesgo?).
- Validación con el equipo de investigación: verificación de que los patrones identificados son coherentes con el conocimiento experto sobre la FCBI.

Entregable: Informe comparativo de modelos y reporte de variables predictoras relevantes.

Etapas 5. Documentación y transferencia

Esta etapa corresponde a la fase 6 de CRISP-DM (despliegue). Dado que el despliegue completo está previsto como trabajo futuro en el sistema del co-investigador, esta etapa se centra en la documentación técnica que habilite esa integración.

Actividades:

- Documentación técnica del modelo: descripción del pipeline de preprocesamiento, parámetros del modelo final, instrucciones de uso y limitaciones conocidas.
- Empaquetado del modelo en formato exportable (pickle / joblib) para su futura integración en la plataforma del proyecto longitudinal.
- Elaboración del artículo científico y preparación de ponencia para evento académico.
- Elaboración del informe final del trabajo de grado y manuales correspondientes.

Entregable: Modelo exportado y documentado, manual técnico de integración, artículo científico, informe final.

7. CRONOGRAMA DE ACTIVIDADES

Tabla 2. Cronograma de actividades del proyecto.

Id	Actividad	Mes					
		1	2	3	4	5	6

1	Revisión de literatura y estado del arte						
2	Reuniones de definición del problema y variables objetivo						
3	Solicitud, recepción e inventario de bases de datos						
4	Exploración visual de datos con Power BI						
5	Limpieza, integración y automatización ETL (Python)						
6	Análisis de desbalanceo y partición del conjunto de datos						
7	Transferencia de datos procesados al compañero investigador						
8	Selección y entrenamiento de modelos candidatos						
9	Ajuste de hiperparámetros y validación cruzada						
10	Evaluación comparativa de modelos						
11	Validación con el equipo de investigación						
12	Documentación técnica y empaquetado del modelo						
13	Elaboración de artículo científico / ponencia						
14	Elaboración del informe final						

Duración total del proyecto: 6 meses.

8. PRESUPUESTO Y FINANCIACIÓN

El proyecto no requiere financiación en efectivo. Se emplean exclusivamente herramientas de código abierto o de uso libre académico y los equipos disponibles del estudiante y la universidad. El presupuesto se valora en especie.

Tabla 3. Presupuesto global del proyecto por tipo de recurso.

RESUMEN DEL PRESUPUESTO GENERAL
